PLANO DE AULA

EdgeAI_Vision: da API à criação da IA

Desconstruindo o projeto em ordem reversa • 40 minutos

DURAÇÃO	PÚBLICO	ESTRATÉGIA	EIXO
40 min	Iniciantes	Demonstração + investigação	Do resultado à origem

1. Intenção pedagógica

Partir de uma API de detecção em funcionamento e, em etapas curtas, revelar as peças que tornam o resultado possível: endpoints, arquivos da aplicação, modelo ONNX, treinamento YOLO Small, dados e pipeline criada com apoio do Google Antigravity. A aula prioriza compreensão conceitual, não programação linha a linha.

2. Objetivo geral

Compreender como os componentes de um sistema de Visão Computacional de Borda se conectam, desde a requisição à API até a preparação e o treinamento do modelo que detecta equipamentos de proteção individual (EPIs).

3. Resultados de aprendizagem esperados

- Descrever o caminho básico: cliente → endpoint/API → inferência → modelo ONNX → resposta.
- Diferenciar a responsabilidade de main.py, inference.py, endpoints e Docker.
- Explicar, em linguagem simples, dataset, YAML, YOLO Small, epoch, checkpoint e ONNX.
- Interpretar Precision, Recall, mAP50 e mAP50–95 sem tratá-las como uma única “acurácia”.
- Identificar limitações observadas e propor próximos testes para capacetes e coletes.

4. Recursos e preparação prévia

- Apresentação EdgeAI_Vision_YOLO_Small_Apresentacao_Reversa.pptx.
- Raspberry Pi/API e uma imagem de teste; ter à mão captura de tela ou resposta de exemplo como plano alternativo.
- Arquivo results2.csv, com as métricas finais do epoch 10; conexão/projeção para mostrar os resultados.
- Antes da aula, confirmar serviço, endpoint, conectividade e que mock_mode está false. Não afirmar que há inferência real sem verificar.

Regra de condução Use o ciclo “O quê? Pra quê? Como?” em cada etapa. Explique a sigla na primeira vez em que aparecer e mantenha o detalhe técnico subordinado à ideia principal.

5. Sequência didática — 40 minutos

A sequência abaixo acompanha os 22 slides da apresentação. O cronograma é intencionalmente enxuto: demonstre o fluxo, destaque a função de cada peça e evite abrir código em profundidade nesta aula introdutória.

Tempo	Slides	Foco	Ação do docente	Evidência rápida
0–4 min	Slides 1–3	Começar pelo resultado	Mostrar a saída esperada. Perguntar como ela foi produzida; explicar status e mock_mode=false.	Aluno descreve o que vê: serviço, classes ou resultado da requisição.
4–7 min	Slide 4	Visão Computacional de Borda	Traçar imagem → Raspberry Pi → detecções. “Borda” é processar perto da origem dos dados.	Aluno identifica por que processar localmente pode reduzir dependência da nuvem.
7–10 min	Slide 5	Dois endpoints	Comparar POST /predict (JSON) e POST /predict/image (imagem anotada); definir endpoint/HTTP/JSON.	Pergunta relâmpago: qual endpoint é melhor para outro software? E para inspecionar visualmente?
10–14 min	Slides 6–7	main.py e inference.py	Usar “porteiro” e “especialista”: main.py encaminha; inference.py prepara a imagem e lê a saída do modelo.	Aluno associa cada arquivo à sua responsabilidade.
14–16 min	Slide 8	Docker	Explicar Dockerfile como receita, imagem como pacote e container como aplicação em execução.	Aluno explica em uma frase por que empacotar o ambiente ajuda a repetir a execução.
16–20 min	Slide 9	ONNX	Mostrar a transição best.pt → exportação → best.onnx. Definir checkpoint e ONNX; lembrar que ONNX é o formato usado na inferência implantada.	Aluno distingue arquivo de checkpoint treinado do arquivo exportado para inferência.
20–27 min	Slides 10–15	Dados e treinamento YOLO Small	Mostrar SH17/5 classes, YAML, YOLO Small, Colab/T4, 10 epochs, métricas e best.pt/last.pt.	Aluno relaciona exemplos anotados, treinamento, avaliação e seleção do checkpoint.
27–32 min	Slides 16–18	Pipeline e Antigravity	Explicar a sequência, vibe coding e Skill.md. Reforçar testes, logs e revisão humana do código gerado.	Aluno aponta uma verificação humana necessária antes de confiar na pipeline.
32–36 min	Slides 19–20	Limitações e melhorias	Pessoas, luvas e óculos já são identificados; há confusão com capacetes e coletes não são identificados. Sugerir novos testes.	Aluno propõe uma hipótese de melhoria que possa ser verificada.
36–40 min	Slides 21–22	Síntese e checagem final	Retomar a cadeia completa e conduzir três perguntas de saída. Usar o glossário somente para esclarecer termos que ainda bloqueiem a compreensão.	Verificar se o aluno entende o sistema como conjunto de componentes e não como uma única “IA mágica”.

Valores do results2.csv no epoch 10: Precision 78,8% • Recall 68,5% • mAP50 72,9% • mAP50–95 50,9%.

6. Roteiro de fala e perguntas-chave

Momento	Fala sugerida	Pergunta à turma
Abertura	“Esta API recebe uma imagem e devolve um resultado. Vamos descobrir as peças que tornam isso possível.”	O que você acha que acontece entre enviar a imagem e receber o resultado?
Aplicação	“main.py organiza a conversa; inference.py faz a ligação com o modelo.”	Qual dos arquivos recebe/organiza a requisição? Qual lida com a inferência?
Treinamento	“O modelo aprende padrões a partir de exemplos anotados; uma epoch é uma passagem completa pelos dados de treino.”	Por que diversidade e qualidade das imagens importam?
Métricas	“Precision avalia a correção das detecções feitas; Recall, o quanto dos objetos reais foi encontrado. mAP resume qualidade de detecção em condições definidas.”	Um bom resultado geral garante que cada uma das cinco classes funcione bem?
Fechamento	“A IA não é infalível: medimos, analisamos erros e melhoramos os dados/modelo.”	Qual seria o próximo teste para investigar a falha em capacetes ou coletes?

7. Avaliação formativa — bilhete de saída

Nos últimos quatro minutos, peça respostas orais rápidas ou que os estudantes anotem respostas curtas para estas três questões:

- 1. Em uma frase, qual é a diferença entre main.py e inference.py?
- 2. O que significa dizer que o treinamento foi realizado por 10 epochs?
- 3. Cite uma melhoria que investigaria para aumentar a detecção de capacetes ou coletes.

Critério de sucesso O estudante descreve o fluxo básico, diferencia pelo menos dois componentes e sugere uma melhoria testável. Não exigir memorização de nomes de funções ou detalhes internos do código.

8. Conceitos que precisam ser definidos sem aprofundar

Termo	Explicação para iniciantes
API / endpoint	Interface entre programas / endereço que oferece uma função específica.
Inferência	Usar um modelo já treinado para analisar uma nova imagem.
Dataset / YAML	Conjunto de imagens anotadas / arquivo de configuração dos dados e classes.
YOLO Small	Variante de tamanho small da família YOLO usada para detectar objetos.
Epoch / checkpoint	Uma passagem completa pelo conjunto de treino / arquivo que guarda parâmetros do modelo.
Precision / Recall	Proporção de detecções corretas / proporção de objetos reais encontrados.
mAP50 / mAP50–95	Métricas médias de precisão de detecção; a segunda avalia múltiplos limiares de IoU.

IoU / ONNX	Sobreposição entre caixa prevista e referência / formato portátil para representar modelos.
GPU T4 / Skill.md	Processador paralelo NVIDIA usado no Colab / arquivo de instruções que orienta o agente de IA.

9. Guia rápido do docente — visão de bolso

Use esta página como lembrete durante a aula. A prioridade é manter a narrativa reversa e o tempo sob controle.

Tempo	Âncora	Lembrete
0–4	API responde	Mostre o resultado primeiro. Faça a turma formular hipóteses.
4–10	Borda + endpoints	Onde o processamento acontece? Qual a diferença entre JSON e imagem anotada?
10–16	Arquivos + Docker	main.py encaminha; inference.py executa a inferência; Docker empacota ambiente.
16–20	ONNX	best.pt é checkpoint; best.onnx é a versão exportada para inferência.
20–27	Dataset + treino	SH17/5 classes, YAML, YOLO Small, Colab/T4, 10 epochs, métricas e checkpoints.
27–32	Antigravity	Pipeline gerada com apoio de agente e Skill.md; revisar e testar é obrigatório.
32–36	Limitações	Capacetes confundidos; coletes ainda não identificados. Investigar por classe.
36–40	Síntese	Peça a explicação de main.py vs inference.py, epoch e uma melhoria.

10. Plano alternativo se a demonstração falhar

- Não gastar mais de 60 segundos tentando consertar ao vivo. Abrir a captura de tela ou resposta previamente preparada.
- Deixar claro que a tela é uma evidência de exemplo, não uma confirmação do estado atual do serviço.
- Continuar a aula usando a resposta para explicar o caminho cliente → API → inferência → modelo → resposta.

11. Cuidados pedagógicos

- Evite afirmar que “78,8% é a acurácia”. É a Precision registrada no epoch 10; cada métrica mede um aspecto diferente.
- Não conclua a causa dos erros de capacete/colete sem examinar exemplos e métricas por classe. Apresente causas possíveis como hipóteses.
- Não entrar em instalação de dependências, código linha a linha ou ajuste detalhado de hiperparâmetros; são temas para outra aula.

Mensagem final para a turma Construir IA envolve dados, código, avaliação e implantação. A qualidade não se prova apenas porque a API responde: é preciso verificar o que o modelo detecta, o que deixa passar e como melhorar.